

Relatório de Business Intelligence

Cloud Analytics com Olist

Disciplina: Tópicos Avançados em Banco de Dados

Equipe: Sandes · Vitória Melo · Helder · Ilky

Junho de 2026

Resumo Executivo

Este relatório consolida os resultados da análise de Business Intelligence desenvolvida sobre os dados públicos da Olist, a partir de um Data Warehouse modelado em esquema estrela (Star Schema), implementado no Supabase (PostgreSQL), populado via pipelines de ETL no Apache Hop, e visualizado em um dashboard interativo no Preset.io (Apache Superset).

A análise identificou padrões relevantes de concentração de receita por categoria de produto e por região, diferenças expressivas no comportamento de pagamento dos clientes, desempenho heterogêneo entre vendedores, e rotas logísticas específicas com custo de frete desproporcional ao valor do produto — sinalizando os principais gargalos operacionais e oportunidades comerciais da operação.

Principais destaques

- Receita fortemente concentrada em poucas categorias (beleza_saude, relorios_presentes e cama_mesa_banho lideram o faturamento).
- São Paulo (SP) concentra isoladamente a maior parcela da receita entre os estados de clientes, com uma cauda longa de baixa penetração no restante do país.
- Cartão de crédito domina as transações ($\approx 74\%$ dos pedidos) e é o único meio com parcelamento relevante.
- Existem rotas cliente↔vendedor em que o frete chega a representar até 48% do preço do produto — gargalo logístico claro.

1. Introdução

A Olist é uma plataforma de marketplace que conecta lojistas parceiros a clientes em todo o território brasileiro. O objetivo deste projeto foi desenvolver uma arquitetura moderna de dados em nuvem para transformar os dados operacionais (transacionais) da Olist em uma estrutura analítica (dimensional), permitindo a geração de insights de negócio através de um dashboard de BI.

O projeto foi dividido em três etapas técnicas — modelagem dimensional, pipeline de ETL e visualização — cujos resultados consolidados são apresentados neste documento, com foco na etapa de análise de negócio.

2. Arquitetura da Solução

O Data Warehouse foi modelado como um Star Schema com grão de 1 linha por venda, composto pela tabela fato fato_vendas e pelas dimensões dim_cliente, dim_vendedor, dim_produto, dim_pagamento e dim_tempo. A carga foi realizada via pipelines Apache Hop (.hpl) orquestrados por workflows (.hwf), com geração de surrogate keys nas dimensões antes da carga na fato. O ambiente de BI foi conectado ao Supabase via Preset.io (Apache Superset), onde foram construídos os datasets e gráficos analisados a seguir.

3. Perguntas de Negócio Respondidas pelo Dashboard

O dashboard foi construído para responder às cinco perguntas de negócio a seguir, cada uma associada a um gráfico específico:

1. Quais categorias de produto geram mais receita para o negócio?
2. Quais estados concentram a maior receita de clientes, e quais representam oportunidades de expansão?
3. Como o comportamento de pagamento (forma e parcelamento) varia entre os clientes?
4. Quais vendedores apresentam melhor desempenho de vendas na plataforma?
5. Quais rotas entre o estado do cliente e o estado do vendedor apresentam maior custo logístico relativo (frete sobre preço do produto)?

4. Análise dos Resultados

4.1 Receita por Categoria de Produto

As dez categorias de maior receita concentram a maior parte do faturamento da plataforma, com destaque para produtos de beleza/saúde e itens de presente:

Categoria	Receita Total (R\$)	Qtd. Vendas
beleza_saude	1.441.429,69	9.670
relogios_presentes	1.305.541,61	5.991
cama_mesa_banho	1.241.681,72	11.115
esporte_lazer	1.158.323,20	8.641
informatica_acessorios	1.059.272,40	7.827
moveis_decoracao	903.245,78	8.334
utilidades_domesticas	779.318,81	6.964
cool_stuff	719.329,95	3.796
automotivo	685.489,44	4.235
ferramentas_jardim	584.427,64	4.347

Insight: beleza_saude lidera em receita mas não em volume, indicando ticket médio elevado; já cama_mesa_banho tem o maior volume de vendas (11.115), sugerindo um produto de entrada com menor margem unitária.

4.2 Receita por Estado do Cliente

O gráfico evidencia forte concentração geográfica: São Paulo (SP) lidera com receita muito superior aos demais estados (próximo de R\$ 6 milhões), seguido por Minas Gerais (MG), Paraná (PR) e Santa Catarina (SC). A partir daí, observa-se uma cauda longa decrescente até estados como Roraima (RR), com participação marginal no faturamento total.

[A CONFIRMAR] Inserir aqui a tabela com os valores exatos de receita por estado, exportada do Preset (Resultados → Download), antes da entrega final.

4.3 Comportamento de Pagamento

A forma de pagamento predominante é o cartão de crédito, respondendo por mais de 74% dos pedidos e sendo o único meio com parcelamento médio relevante:

Forma de Pagamento	Qtd. Pedidos	Ticket Médio (R\$)	Parcelas (média)
credit_card	83.947	146,44	3,67
boleto	22.867	124,32	1,00
voucher	4.143	119,93	1,78
debit_card	1.690	127,40	1,00

Insight: boleto e cartão de débito são essencialmente pagamentos à vista (1 parcela), com ticket médio semelhante entre os quatro meios — a diferença está concentrada no volume e na flexibilização do pagamento, não no valor do pedido.

4.4 Desempenho dos Vendedores

O ranking dos vendedores por receita total mostra forte concentração em São Paulo, com uma exceção notável na Bahia (vendedor de Lauro de Freitas), que apresenta receita elevada com volume bem menor — indicando ticket médio por venda muito acima da média (R\$ 575,26):

Vendedor (ID)	Estado	Cidade	Receita (R\$)	Vendas	Ticket Médio (R\$)
4869f7a5...	SP	guariba	249.640,70	1.156	215,95
7c67e144...	SP	itaquaquecetuba	239.536,44	1.364	175,62
53243585...	BA	lauro de freitas	235.856,68	410	575,26
4a3ca931...	SP	ibitinga	235.539,96	1.987	118,55
fa1c13f2...	SP	sumare	204.084,73	586	348,27

Insight: o vendedor de Lauro de Freitas (BA) opera com um modelo de poucas vendas de alto valor, enquanto a maioria dos top vendedores em SP opera com alto volume e ticket médio mais baixo — dois perfis comerciais distintos que podem orientar estratégias de suporte diferenciadas por vendedor.

4.5 Gargalos Logísticos — Custo de Frete por Rota

Para identificar gargalos logísticos, calculou-se o frete médio e sua proporção em relação ao preço do produto (pct_frete_sobre_preco) por rota entre o estado do cliente e o estado do vendedor, considerando apenas rotas com no mínimo 10 vendas para garantir significância estatística:

Cliente	Vendedor	Frete Médio (R\$)	Qtd. Vendas	% Frete/Preço
PB	SC	72,50	20	22%
CE	SC	70,28	23	20%
PI	PR	61,35	32	22%
PA	SC	59,95	21	20%
RJ	CE	59,75	10	15%
PE	RS	59,21	18	24%
RS	MA	54,42	17	48%
PA	PR	53,53	60	19%

Insight: a rota RS→MA se destaca negativamente — o frete médio (R\$ 54,42) não é o mais alto em valor absoluto, mas representa 48% do preço do produto, quase o dobro da proporção das demais rotas listadas. Isso indica um gargalo de eficiência logística específico dessa rota, não apenas de distância.

5. Síntese: Principais Gargalos Logísticos

- Rotas de longa distância com baixo volume de vendas (ex.: RS→MA, PE→RS) apresentam custo de frete proporcionalmente muito acima da média, encarecendo o produto final para o cliente e possivelmente reduzindo a conversão nessas regiões.
- A ausência de uma chave de tempo (sk_tempo) na tabela fato_vendas impede, nesta versão do projeto, a análise de prazos de entrega e sazonalidade — ver seção 7 (Limitações).
- Vendedores concentrados em poucos estados (majoritariamente SP) sugerem dependência logística regional, o que pode ampliar o custo de frete para clientes em estados mais distantes desses polos.

6. Síntese: Principais Oportunidades de Vendas

- Categorias de alto ticket médio (beleza_saude, relorios_presentes) têm potencial para campanhas de cross-sell com categorias de alto volume e menor ticket (cama_mesa_banho), aumentando o valor médio do carrinho.
- Estados fora do eixo SP-MG-PR-SC representam baixa penetração de receita — candidatos a campanhas regionais de aquisição de clientes, especialmente se combinados com vendedores locais para reduzir o custo de frete.
- Usuários de boleto e voucher (pagamento à vista) podem ser incentivados a migrar para cartão de crédito parcelado, potencialmente aumentando o ticket médio, como já ocorre com os clientes de credit_card.
- O perfil de vendedor de alto ticket e baixo volume (ex.: Lauro de Freitas/BA) pode servir de modelo para recrutar ou capacitar vendedores fora do polo SP, diversificando a base logística.

7. Limitações dos Dados e Recomendações Futuras

- dim_tempo sem FK na fato: a dimensão de tempo não está conectada à fato_vendas por chave estrangeira (sk_tempo ausente), o que impede análises de evolução temporal e sazonalidade nesta versão. Recomenda-se ajustar o pipeline fato_vendas.hpl no Apache Hop para incluir essa busca antes da próxima carga.
- Ausência de data de entrega: a fato_vendas não possui campos de data de entrega ou prazo, o que limitou a análise de gargalos logísticos ao custo de frete relativo (pct_frete_sobre_preco) como proxy, em vez de atraso efetivo de entrega.
- Inconsistência de tipo de dado: a coluna sk_cliente é do tipo double precision em dim_cliente e bigint em fato_vendas. O join funciona por conversão implícita, mas a padronização do tipo é recomendada em versões futuras do modelo.
- Simplificação no pagamento por pedido: quando um pedido possui múltiplas linhas em dim_pagamento (ex.: pagamento misto ou parcelas registradas individualmente), a forma de pagamento foi simplificada com MAX(payment_type), o que pode sub-representar pagamentos mistos em um mesmo pedido.
- Cobertura de dados: nem todos os datasets de origem do repositório Olist foram tratados nesta primeira versão do pipeline; recomenda-se validar a completude da carga antes de decisões de negócio definitivas.

8. Conclusão

A arquitetura de dados em nuvem construída neste projeto — Supabase, Apache Hop e Preset.io — permitiu transformar os dados públicos da Olist em um conjunto de cinco análises de negócio diretamente acionáveis, cobrindo desempenho de produto, geografia, pagamento, vendedores e logística. Os principais achados apontam para uma concentração de receita em poucas categorias e estados, um comportamento

de pagamento dominado pelo cartão de crédito parcelado, e gargalos logísticos pontuais identificáveis pela relação entre frete e preço do produto. As limitações documentadas na seção 7 indicam os próximos passos técnicos para aprofundar essa análise em versões futuras do Data Warehouse.

9. Anexos

- Dashboard interativo (Preset.io): [A CONFIRMAR — inserir link de acesso Viewer]
- Repositório do projeto (GitHub): [A CONFIRMAR — inserir link do repositório]
- Documentação da modelagem dimensional (Etapa 1): ver README.md principal do repositório.